2023 年度　　卒業論文

長時間動画のオンライン事前学習方法の検討

2024 年 2 月 15 日　玉木研究室

No. 32114041　加藤樹

1　はじめに

動画像を認識するタスクで用いられる動画像には，大きく分けて trimmed video と untrimmed video の 2 種類がある．trimmed video は，元となる動画像から切り出された（トリミングされた）数秒から 10 秒程度の比較的短い動画像であり，1 つの untrimmed video に対して 1 つのラベルが付与されていることが多い [1, 2, 3, 4]．untrimmed video とはトリミングされていない数分から数十分程度の動画像であり，通常はフレーム単位のラベルがアノテーションされている [5, 6, 7]．

上記の動画像を利用する研究の多くは，ローカルの記憶媒体に保存された動画ファイルを用いており，学習も推論もオフライン処理を想定している．しかし近年の動画ストリーム配信プラットフォームの隆盛の影響により，動画をオンラインで認識するための研究も行われている [8, 9]．オフラインで trimmed video を学習する場合は，画像認識と同様に学習サンプルとなる動画像をランダムに選択して（さらにその中のランダムな位置のクリップを抽出して）モデル更新に利用する方法が一般的である．untrimmed video の場合には複数の（固定長または可変長の）trimmed video（クリップ）に分割し，特徴量を事前計算しておくことが多い．一方で動画ストリームの場合はランダムなクリップを選択したり特徴量を事前計算しておくことができないため，これまでのアプローチでは主に以下の 2 点が考慮されている．1 点目は計算コストである．動画ストリームに対してリアルタイム処理を行う場合には各時刻で得られるフレームを高速に処理する必要があるが，動画像を認識するモデルは一般的に計算コストが高い [10, 11]．そのためオンライン認識のための効率的なモデル [9, 12, 13, 14] が提案されている．2 点目は学習方法である．多くのオンライン手法は因果推論（causal inference），つまりその時点以降の将来のフレームの情報は推論には利用しない．しかし学習は trimmed video などを用いたオフラインで行っており，したがって non-causal な学習を行うものが多い [8, 12, 15]．そのためオンラインで causal に学習する手法も提案されている [9, 16, 17, 18, 19]．

本研究ではこれまで考えられていない第 3 の点に着目する．上述のように，一般的な動作認識モデル [11, 20, 21, 22, 23] では trimmed video から動画クリップをランダムに選択して学習することが一般的である．これらのモデルを untrimmed video や動画ストリームなどの長時間動画で causal に学習する場合には，1 つの長時間動画像から連続したクリップを学習し続けることになる．この方法の利点は，動画配信プラットフォームなどから大量に得られるラベルなしの長時間動画像を利用できることであり，自己教師あり学習 [24] によるモデルの事前学習に適した方法である．しかし連続する動画クリップはそのコンテンツが冗長であることが多く，それらを動作して認識モデルの学習に利用した場合には，性能の劣化が予想される．したがって，モデルの事前学習に連続する動画クリップを用いた場合の影響を調査することは重要であるが，これまでそのような研究は行われていない．

そこで本研究では，事前学習のためにオンラインでモデルを学習する具体的な方法論として，以下の 3 つの方法を検討する．1 つ目は Masked Image Modeling (MIM) [10, 25, 26, 27, 28] である．これは Vision Transformer (ViT) [29] へ入力するパッチをランダムにマスクし，その内容を予測させる自己教師あり学習のための pretext タスクであり，本研究では VideoMAE [10] を利用する．2 つ目は対照学習を用いた自己教師あり学習 [24, 30, 31] である．これは 1 つの学習サンプルを複数のエンコーダに入力した埋め込み同士を近づけるように学習する手法であり，本研究ではモーメンタムエンコーダを用いる MoCo [32, 33] を利用する．3 つ目は，Teacher-Student 型の知識蒸留 [34, 35] である．これは事前学習済みの teacher モデルの出力に一致するように student モデルを学習する手法であり，本研究では動作認識データセットで事前学習済みの既存モデルを teacher モデルに利用する．

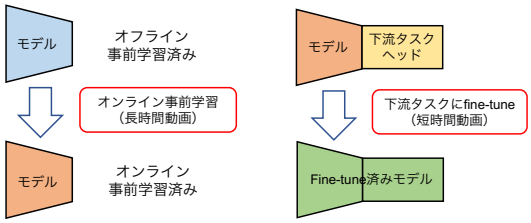


図 1: 本研究の概要．(a) 事前学習においては長時間動画を用いてオンラインでモデルを学習する．(b) 下流タスクでは，事前学習で得られたモデルを fine-tuing して性能を評価する．

本研究の貢献は以下の通りである．

- 長時間動画を用いてモデルの事前学習をオンラインで行うことの有用性について検討し，具体的な方法論を示す．特に一般的な動作認識モデルをオンラインで学習した場合の影響はこれまで研究されておらず，どのような学習方法を用いれば適切に学習が行えるのかを示す研究はこれが初めてである．
- 学習したモデルを様々な下流タスクで評価し，提案する方法が有効であることを示す．一般的な方法で trimmed video で事前学習した場合と比較して，性能がどの程度異なるのかを定量的に示し，どのハイパーパラメータの影響が最も大きいのかを明らかにする．

2　関連研究

2.1　動作認識モデル

動作認識など動画像理解のための手法は多数提案されており [11, 20, 36, 37, 38]，近年では Vision Transformer [29] や CLIP [39] を動画像認識へ適用した研究が数多く行われている [22, 23, 40, 41, 42, 43]．これらの多くは，trimmed video からなる Kinetics [44] や UCF101 [45] などのデータセットをオフラインで学習するものである．

2.2　効率的な動画像認識モデル

動画像を効率的に学習するための軽量な手法は多数提案されている．X3D [20] や MoViNet [9] は 3D CNN のアーキテクチャを Network Architecture Search (NAS) によって探索することで，動画像認識の際の

メモリ使用量や計算量を削減している．またフレーム毎の 2D CNN と late fusion によって時空間の 3 次元情報を効率的に処理する手法は CNN [14, 46, 47] や ViT [21, 48, 49] を用いた研究でも採用されている．時間方向と空間方向を分離することで計算量低減を目指した研究も数多く提案されている [22, 23, 50, 51]．

これらの手法は主に trimmed video からサンプルされた動画クリップを扱うためのものである．本研究ではこれらを含めて，動画クリップを入力とする一般的な動作認識モデルをどのようにオンラインで学習するべきかという方法論を検討する．

2.3　長時間動画の認識

動画クリップは 8 フレームや 16 フレームからなることが多く，時間的に短いため，1 つの動画クリップだけを扱う動作認識モデルは時間的に離れたフレームの情報を相互利用することはできない．そのため，長時間動画を扱うようにモデルを拡張する手法も提案されており，連続するクリップ間のマルコフ性を利用する方法 [52]，メモリを利用してクリップ間の情報のやり取りを行う方法 [53]，離れたクリップ間の特徴を直接対照学習したり [54] 物体をマスクして対照学習する方法 [55] などがある．これらは長い時間スパンの依存関係をモデル化することが目的であり，オンラインでモデルを学習することは考慮されていない．

2.4　オンラインでの動画像認識

オンラインで動画像を causal に学習する手法も提案されている [9, 16, 17, 18, 19]．Sideway とその関連手法 [16, 17, 18] はオンラインに特化したモデルであり，オンラインで動画像の 1 フレームがモデルに入力される毎に，ネットワーク内での処理を 1 層進める構造を採用している．MoViNet [9] は動画像を逐次的にクリップに分割しモデルへ入力するが，動画全体のクリップが入力されるまで勾配更新を行わない gradient accumulation を採用している．MeMViT [19] は MViT [56] を改良したモデルで，逐次的にオンライン形式でフレームを処理する際に，中間特徴量をメモリにキャッシュする構造をとっている．各時刻 t におけるフレームの処理ではこの時刻 $t-1$ のメモリを利用し，それ以前の特徴は圧縮することでメモリ使用量を削減しつつ長期的な時間的サポートを実現している．

これらの手法はオンラインに特化したアーキテクチャであり，一般的な動画クリップを入力とする動作認識モデルに利用できるものではない．本研究では一般的なモデルを対象として，オンラインでの causal な学習を実現するための方法論を検討する．

3　オンライン事前学習のための教師なし学習

本節では，ストリーミング動画や untrimmed video などの長時間の動画を用いて，オンラインで動画像モデルを事前学習するための方法について述べる．

3.1　動画像クリップの作成方法

まず動画像モデルに入力する単位である動画像クリップの作成方法について述べる．与えられた長時間動画像データセットを $V = \{v_o, v_1, ..., v_N\}$ とする．ここで各 $v_i \in \mathbb{R}^{T_i \times 3 \times H \times W}$ はフレーム数 T_i の動画像である．V がストリーミング動画であれば $N = 1$，untrimmed video のデータセットであれば $N > 1$ である．また H, W はフレームの高さと幅であり，全ての動画像で共通であると仮定する．

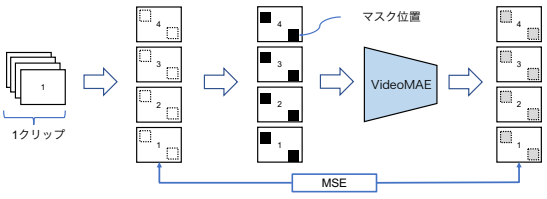


図 2: videoMAE の概要図．クリップに対し，時間方向に同じ箇所マスクし，再構成するタスクを行う．

このデータセット中の 1 本の動画像 $v_i \in \mathbb{R}^{T_i \times 3 \times H \times W}$ から T フレームをストライド s で連続的に切り出した動画像クリップを

$$x_{i,n} = v_i[nsT : (n+1)sT : s, :, :, :] \in \mathbb{R}^{T \times 3 \times H \times W} \tag{1}$$

とする（なおこれは python でのスライシング記法を用いて表現している）．ここで n は動画像クリップのインデックスであり，v_i については $n_i = \lfloor \frac{T_i}{sT} \rfloor - 1$ として $n = 0, 1, \ldots, n_i$ の範囲の値をとる．なお動画の末尾において指定したフレーム数が取得できない場合には，その動画像クリップは破棄し，学習には使用しない．

本研究では，長時間動画の先頭から逐次的に $x_{0,0}, x_{0,1}, \ldots, x_{0,n_0}, x_{1,0}, \ldots, x_{1,n_1}, \ldots x_{N,n_N}$ と切り出した動画像クリップをモデルの事前学習のために使用する．なお記法の簡略化のために，添字 i, n が重要ではない場合には x と省略して書く．

3.2　MIM

本研究では MIM に VideoMAE [10] を用いる（図 2）．これは，動画像クリップに対して時間方向にマスクをかけて，マスクされてない箇所を ViT エンコーダに入力し，マスク箇所の画素値をデコーダで再構成するモデルである．まず入力動画像クリップ $x \in \mathbb{R}^{T \times 3 \times H \times W}$ の各フレームを ViT で扱うために，16×16 画素のパッチに分割する．そしてランダムに 50% に相当する J 個のパッチを（ただし全フレームにおいて同じ位置のパッチを）マスクする．マスク関数を I として，動画像クリップのマスクされたパッチ j の画素値を $I(x)_j \in \mathbb{R}^{T \times 3 \times 16 \times 16}$ と表す．そしてマスクされたパッチ j の画素値を再構成した出力を $\hat{I}(x)_j$ とする．この 2 つの差を最小化するための損失関数は以下のものである．

$$L = \frac{1}{\Omega} \sum_{j=1}^{J} \| I(x)_j - \hat{I}(x)_j \|^2 \tag{2}$$

ここで，$\Omega = 3 \cdot 16^2 TJ$ はマスクされたパッチの全画素数である．

3.3　対照学習

対照学習とは，自己教師あり学習の 1 つであり，ラベル付けを行うことなく，データ同士を比較し，似たデータは近くに，異なるデータは遠ざけるように学習を行う手法である．

本研究では対照学習に momentum encoder を導入した MoCo [32] を用いる（図 3）．入力動画像クリップ x を encoder に，x に対してデータ変換させたクリップ x_{trans} を momentum encoder に入力する．データ

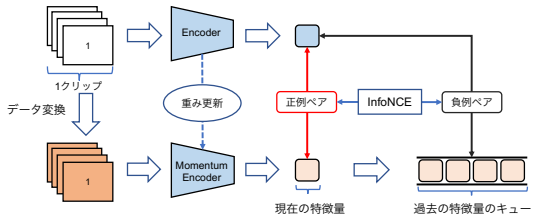


図 3: MoCo の概要図．クリップに対して通常のクリップを encoder に，データ変換したクリップを momentum encoder に入力する．現在の特徴量をペアを正例として，過去の特徴量を負例として扱い，これらの対照学習を行う．

拡張に関しては，クリップ x の各 RGB フレームを GBR に変換し，水平方向に反転したものを x_{trans} とする．Encoder を E，momentum encoder を M として，入力クリップ x に対する出力をそれぞれ q, k とすると処理は以下となる．

$$E(x) = q \tag{3}$$

$$M(x_{trans}) = k \tag{4}$$

これらの encoder と momentum encoder の 2 つの出力から，損失の計算を行う．

損失関数は infoNCE [57] として，以下となる．

$$L = -\log \frac{\exp(q \cdot k_+/\tau)}{\exp(q \cdot k_+/\tau) + \sum_{t \in K} \exp(q \cdot k_t/\tau)} \tag{5}$$

ここで，k_+ は入力クリップ x の正例クリップを指定するキーである．また，正例と負例の設定については，オンライン学習のための設定のため，現時刻で取得したクリップは正例として，それに対して過去に取得したクリップは負例とみなす．不例クリップはキューに蓄積させるものとし，K は負例クリップの数とする．τ は温度パラメータである．現時刻で取得したクリップに対する encoder と momentum encoder の出力 q, k の積 $q \cdot k$ によって類似度を獲得する．負例も，同様に q と負例クリップのキューとの積により類似度を獲得する．これによって獲得した正例と負例の類似度を正例と正例は近づけ，正例と負例は遠ざけるように学習を行う．

重み更新は BPTT（Back Propagation Through Time）ではなく，encoder と momentum encoder 同士での平均移動によって行う．

$$\theta_m = p\theta_m + (1-p)\theta e \tag{6}$$

ここで，θ_e は encoder の重み，θ_m は momentum encoder の重み，p は移動パラメータとして，$p = 1$ の場合は更新は行わずに $p = 0$ の場合は encoder の全ての重みを momentum encoder に更新する．通常は $p = 0.99$ のように大きな値を設定して，徐々に momentum encoder の重みを更新していく．

3.4　Teacher-student 学習

Teacher-student 学習（Teacher-Student Learning, TSL）は，図 4 に示すように，事前学習した teacher モデルと，事前学習済みでない student モデルを用意して，student モデルが teacher モデルの出力と一致するように学習する手法であり，本研究ではこれを student モデルの学習に用いるため，教師なし学習の一種とみなすことにする．

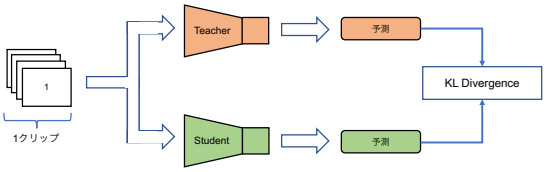


図 4: Teacher-student 学習の概要図．クリップを teacher モデルと student モデルのそれぞれに入力する．student モデルはその出力が teacher モデルの出力と一致することを目指す．

Teacher モデル M_t，student モデル M_s の両方に同じ動画像クリップ x を入力する．出力は予測分布であり，teacher モデルと student モデルの予測をそれぞれ

$$p = M_t(x) \tag{7}$$

$$q = M_s(x) \tag{8}$$

とする．これらを一致させるための損失関数は以下の KL ダイバージェンスである．

$$L = KL(p||q) = \frac{1}{K} \sum_{i \in K} p_i \log \frac{p_i}{q_i} \tag{9}$$

ここで K はクラス数である．本研究では Kinetics-400 [44] で事前学習されたモデルを使用するため，$K = 400$ である．

4　実験

逐次クリップを評価するために，長時間動画を用いて，逐次クリップとランダムクリップの性能比較を行った．比較は，事前学習では各手法の損失関数の大きさで，下流タスクでは Action Recognition [2] タスクの認識率で評価する．

4.1　データセット

本研究では，モデルの事前学習に AVA-Actions [58]，下流タスクに HMDB51 [59] と UCF101 [45] を用いる．

4.1.1　事前学習　AVA-Actions [58] は，235 動画の訓練セットと 64 動画の評価セットからなるデータセットである．アクション数は 80 カテゴリであり，1 動画につき 15 分の untrimmed video がある．本研究では，教師なし学習を用いるため，ラベルは使用しない．

本研究で利用するために数十分程度の長い動画が適しており，他のデータセットとしては，EPIC-Kitchens-100 [60]，50Salads [61]，HowTo100M [62]，Sport-1M [63] が候補として挙げられる．

4.1.2　下流タスク　HMDB51 [59] は，51 カテゴリ，6766 の動画からなる動作認識用データセットである．訓練データは 6766 動画の 70%である 3570 動画，評価データは 30%の 1530 動画に分割する．各カテゴリ少なくとも最低 101 動画存在しており，1 秒から 5 秒程度で，平均 3.15 秒程度である．

UCF101 [45] は，101 カテゴリ，13320 動画からなる動作認識用データセットである．訓練データは 9537，評価データは 3783 動画からなる．1 動画平均 7.21 秒で，最短 1.06 秒の動画から最長が 71.04 秒の動画が存在する．

4.2　クリップの作成方法

実験では，2 種類のクリップ抽出を比較する．

- random：1 つ目は，短時間動画を対象とした方法であり，一般的に UCF101 [45] や Kinetics400 [44] などの学習に用いられている．本研究では AVA-Actions の全長時間動画データセットを 10 秒毎に分割した trimmed video をあらかじめ用意する．学習の際には，trimmed video をランダムに選択し，T フレームをストライド S で取得する．その後，取得した T フレームをシャッフルし，それを 1 クリップとする．$T = 4$，$S = 2$ と設定した場合の 1 クリップ作成方法を図 5(a) に示す．
- sequential：2 つ目は長時間動画の先頭から逐次的にフレームを指定して抽出する方法である．まず，学習セットの長時間動画から順に 1 本選ぶ．その先頭フレームから指定した T 枚の連続するフレームを，指定したストライド S で抽出し，1 クリップとする．$T = 4$, $S = 2$ と設定した場合の 1 クリップ作成方法を図 5(b) に示す．

学習セットは，こうして作成したクリップの各フレームの画素値を平均 0，標準偏差 1 になるように正規化し，画素を 224×224 になるようにリサイズする．

4.3　動画ファイルの読み込み

逐次的にクリップを取得すると，現時刻 t と次の時刻 $t+1$ で類似度高いフレームがモデルに入力され，過学習が危惧される．そこで，本研究では，worker の導入によってこの問題を解決する．データセットの動画ファイル数を F，worker を w，worker の数を n とすると，i 番目 $(1 \leq i \leq n)$ の worker が読み込む動画ファイルは以下の範囲となり，この範囲の動画ファイルを逐次的に読み込む．

$$i\frac{F}{n} \leq w_i \leq (i+1)\frac{F}{n} \tag{10}$$

このように worker を設定することで，別々の worker が別々の動画ファイルの読み込みを行い，モデルに対して $w_1, w_2, w_3, ...w_n$ のループで取得したクリップを入力とすることが可能となる．これにより，結果的にモデルに対して類似度の高いフレームが入力され続けることによる過学習の危惧が解決される．ただし，オンライン動画ストリームが 1 本の場合には適用できず，注意を払う必要がある．

4.4　学習設定

学習についての詳細な設定を示す．optimizer は SGD，学習率は 1e-3，重み減衰は 5e-5，momentum は 0.9 とした．

4.4.1　事前学習

事前学習では，ランダムクリップと逐次クリップで比較を行う．フレーム数は $T = 16$ と共通した設定にして，ランダムクリップはストライド $S = 8$，逐次クリップは $S = 16, 32, 64$ で実験を行った．epoch はストライドの影響によるサンプル数を考慮して，ランダムクリップは 10epoch，逐次クリップでは $S = 16$ で 10epoch を基準として，$S = 32$ では 20epoch，$S = 64$ では 40epoch と設定した．

- MIM：学習設定は上記のものとし，マスク率は 50% と設定する．
- 対照学習：Encoder には 400 [44] で事前学習した X3D-M [20] を用いる．MoCo の設定は，$K = 256$, $\tau = 0.3$，$p = 0.99$ とする．
- Teacher-student 学習：teacher モデルに Kinetics-400 [44] で事前学習した X3D-M [20] を用いる．student モデルは事前学習済みではない X3D-M [20] を用いて学習する．また上記の共通の設定から学習率のみ変更し，1e-2 とする．

4.4.2　動作認識

全ての事前学習済みモデルに対して共通の設定として，HMDB51 [59] では 30epoch，UCF101 [45] では 10epoch と設定した．その他は事前学習と同様に設定した．

4.5　実験結果

4.5.1　MIM

MIM の実験結果を図 6 に示す．事前学習について，図 6(a) および図 6(b) は横軸はステップ数であり，縦軸は損失（MSE）である．ランダムクリップで学習した場合の性能がもっとも低くなった．逐次クリップに関しては，ストライドの大きさに負の相関があり，最小のストライド $S = 16$ で最も性能が低くなった．ストライドの大きさに負の相関があったことは，ストライドが小さくなると，クリップ内フレームの類似性が高くなり，MIM のタスクとしての難易度が低下することを示唆している．

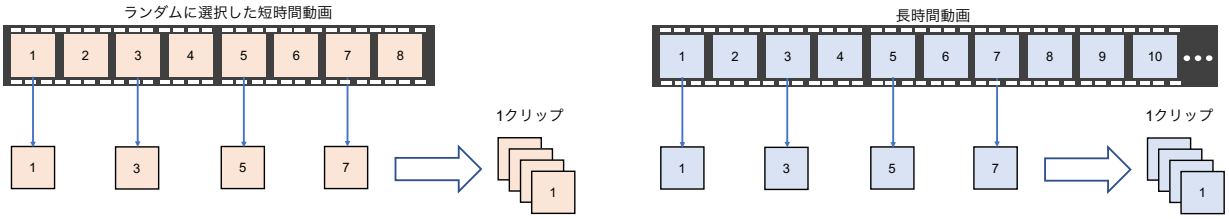
次に下流タスクの結果を図 6(c) から図 6(j) に示す．横軸はエポックであり，縦軸は，図 6(c)，図 6(d)，図 6(g)，図 6(h) では認識率，図 6(e)，図 6(f)，図 6(i)，図 6(j) では下流タスクの損失である．すべての実験設定において，ランダムクリップと同程度の認識率を達成しており，ストライド $S = 64$ で最も性能が高いことがわかる．事前学習の段階で損失関数の数値に差があったにも関わらず，下流タスクで同程度の性能を達成していることから，ストライドの導入によって逐次クリップの過学習が抑えられていると考えられる．しかし，学習時の損失と評価時の損失に差があるため，まだ改善の余地はあるといえる．

4.5.2　対照学習

対照学習の実験結果を図 7 に示す．事前学習の実験結果を図 7(a)，図 7(b) に示す．横軸はステップ数であり，縦軸は損失（infoNCE）である．学習時の損失は逐次クリップとランダムクリップ間での差はないといえる．評価時では，影響が出ており，逐次クリップに関しては，ストライド $S = 64$ の場合がの損失が最も低下しており，ストライドの増加により，離れた場面のフレームがクリップに蓄積されていくため，特徴量の類似度が低下し，汎化性能に繋がったと考えられる．

次に下流タスクの結果を図 7(c) から図 7(j) に示す．横軸はエポックであり，縦軸は図 7(c)，図 7(d)，図 7(g)，図 7(h) では認識率で，図 7(e)，図 7(f)，図 7(i)，図 7(j) では下流タスクの損失である．逐次クリップに関しては，ストライドと性能に正の相関があることがわかる．これは，事前学習においてストライドが大きいと，上述したように過学習に陥りづらいことを示唆している．

比較した 3 つの教師なし学習の中では対照学習が下流タスクの性能が最も高くなった．対照学習は他の教師なし学習とは異なり，動画の特徴量のみから学習を行う手法である．本研究では，同じ動画ファイルから抽出したクリップの特徴量を正例，異なる動画ファイルから抽出したクリップの特徴量を負例として学習を行う．AVA-Actions [58] データセットは物体検出 [64] で一般的に用いられるデータセットであるが，特徴量のみの学習を行うことで，ドメインに依存せず，下流



(a)　　(b)

図 5: 1 クリップの作成方法．(a) random：ランダムで選択した短時間動画からストライド S で 1 クリップだけサンプルする方法と，(b) sequential：長時間動画の先頭からストライド S で逐次的にクリップをサンプルする方法．

タスクの動作認識に応用が可能であるということが示唆される．

4.5.3　Teacher-student 学習　TSL の実験結果を図 8 に示す．事前学習の実験結果は，図 8(a)，図 8(b) であり，横軸はステップ数であり，縦軸は損失（KL ダイバージェンス）である．TSL では，図 8(a) から，学習時ではランダムクリップによる損失が最も大きい損失となり，ストライド $S = 64$ で最も損失が下がった．図 8(b) から，学習時では最も損失の数値が大きかったランダムクリップが，評価時においては最も損失が下がっており，ランダムクリップによる学習が最も汎化することがわかる．逐次クリップの中では，学習時と同様にストライド $S = 64$ での損失が最も小さくなっているが，評価時の損失の数値が下がり切っておらず，汎化ができていないと思われる．

次に下流タスクの結果を図 8(c) から図 8(j) に示す．横軸はエポックであり，縦軸は図 8(c)，図 8(d)，図 8(g)，図 8(h) では認識率で，図 8(e)，図 8(f)，図 8(i)，図 8(j) では下流タスクの損失である．図 8(d) から，HMDB51 [59] に対する性能は最大で 20%，UCF101 [45] では 40%程度と，これらのデータセットに対して通常予想される性能よりもかなり低く，学習が行われていないことがわかる．原因としては，事前学習において teacher モデルからの良い蒸留がなされていないことが考えれらる．本研究では，teacher モデルに kinetics-400 [44] で事前学習をした X3D-M [20] を使用し，AVA-Actions [58] から抽出したクリップを入力とし，対応する 400 クラスを予測する．しかし事前学習においてストライドを導入したことにより，下流タスクである kinetics-400 [44] を予測するための特徴量をうまく獲得することができず，結果的に質の低いランダムな予測に陥ってしまい，student モデルがそれを間違って学習してしまったことが考えられる．

上記の仮説を検証するために，逐次クリップのストライド 16，32，64 おいて，teacher モデルの予測がランダムな予測（kinetics-400 [44] をランダムに予測した 0.0025 の 400 次元ベクトル）と，どの程度離れているかを KL ダイバージェンスによって計算し，1epoch 分を集計した．その結果，ストライド 16 では 3.382，ストライド 32 では 3.373，ストライド 64 では，3.357 となり，ストライドの影響による予測のランダム性が強まる傾向はないといえる．そのため，他の影響が考えられる．AVA-Actions [58] データセットは，映画を元にした長時間動画であり，kinetics-400 [44] のような短い人間の動作が含まれている箇所が少ないと思われる．このようなデータセットの相性の考慮などが挙げられる．

4.5.4　3 つの事前学習手法の比較　本研究では，オンライン事前学習方法に MIM，対照学習，TSL の 3 つの手法で比較を行った．結果的に対照学習によるオンライン事前学習が最も下流タスクで性能を発揮した．

5　おわりに

本論文では，長時間動画のオンライン学習方法の検討を事前学習から逐次的にクリップを読み込むことでオンラインに学習することを，一般的な動作認識モデルで異なる 3 つの教師なし学習を行うことで検討した．今後の課題としては，逐次クリップにおけるクリップ間の相関を低下させることや，様々な下流タスクに応用すること等が挙げられる．

謝辞

本研究を遂行するに当たり，様々な助言を頂いた名古屋工業大学大学院工学研究科工学専攻情報工学系プログラム玉木徹氏，合同中間発表会において様々な助言を頂いた佐藤淳氏，本谷秀堅氏，坂上文彦氏，横田達也氏，佐藤坂上研究室・本谷横田研究室の皆様，ならびに名古屋工業大学玉木研究室の諸先輩に感謝いたします．本研究の一部は，JSPS 科研費 JP22K12090 の助成を受けました．

参考文献

[1] Yu Kong and Yun Fu. Human action recognition and prediction: A survey. *Int. J. Comput. Vis.*, Vol. 130, No. 5, pp. 1366–1401, 2022. 1

[2] Yu Kong and Yun Fu. Human action recognition and prediction: A survey. *International Journal of Computer Vision*, Vol. 130, No. 5, pp. 1366–1401, may 2022. 1, 3

[3] Valter Estevam, Helio Pedrini, and David Menotti. Zero-shot action recognition in videos: A survey. *Neurocomputing*, Vol. 439, pp. 159–175, 2021. 1

[4] Yumeng Zhang, Gaoguo Jia, Li Chen, Mingrui Zhang, and Junhai Yong. Self-paced video data augmentation by generative adversarial networks with insufficient samples. In *Proceedings of the 28th ACM International Conference on Multimedia*, MM '20, pp. 1652–1660, New York, NY, USA, 2020. Association for Computing Machinery. 1

[5] Guodong Ding, Fadime Sener, and Angela Yao. Temporal action segmentation: An analysis of modern technique. *CoRR*, Vol. abs/2210.10352, , 2022. 1

[6] Huifen Xia and Yongzhao Zhan. A survey on temporal action localization. *IEEE Access*, Vol. 8, pp. 70477–70487, 2020. 1

[7] Amlaan Bhoi. Spatio-temporal action recognition: A survey. *CoRR*, Vol. abs/1901.09403, , 2019. 1

[8] Lin Geng Foo, Jia Gong, Zhipeng Fan, and Jun Liu. System-status-aware adaptive network for online streaming video understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 10514–10523, June 2023. 1

[9] Dan Kondratyuk, Liangzhe Yuan, Yandong Li, Li Zhang, Mingxing Tan, Matthew Brown, and Boqing Gong. Movinets: Mobile video networks for efficient video recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 16020–16030, June 2021. 1, 2

[10] Zhan Tong, Yibing Song, Jue Wang, and Limin Wang. Videomae: Masked autoencoders are data-efficient learners for self-supervised video pre-training. In S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems*, Vol. 35, pp. 10078–10093. Curran Associates, Inc., 2022. 1, 2

[11] Christoph Feichtenhofer, Haoqi Fan, Jitendra Malik, and Kaiming He. Slowfast networks for video recognition. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, October 2019. 1

[12] Mohammadreza Zolfaghari, Kamaljeet Singh, and Thomas Brox. ECO: Efficient Convolutional Network for Online Video Understanding. In Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu, and Yair Weiss, editors, *Computer Vision – ECCV 2018*, Vol. 11206, pp. 713–730, Cham, 2018. Springer International Publishing. ECO. 1

[13] Gurkirt Singh, Suman Saha, Michael Sapienza, Philip Torr, and Fabio Cuzzolin. Online Real-Time Multiple Spatiotemporal Action Localisation and Prediction. In *2017 IEEE International Conference on Computer Vision (ICCV)*, pp. 3657–3666, Venice, October 2017. IEEE. 1

[14] Ji Lin, Chuang Gan, and Song Han. Tsm: Temporal shift module for efficient video understanding. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, October 2019. 1, 2

[15] Yucheng Zhao, Chong Luo, Chuanxin Tang, Dongdong Chen, Noel Codella, and Zheng-Jun Zha. Streaming Video Model. In *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 14602–14612, Vancouver, BC, Canada, June 2023. IEEE. S-ViT. 1

[16] João Carreira, Viorica Pătrăucean, Laurent Mazare, Andrew Zisserman, and Simon Osindero. Massively parallel video networks. In Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu, and Yair Weiss, editors, *Computer Vision – ECCV 2018*, pp. 680–697, Cham, 2018. Springer International Publishing. 1, 2

[17] Mateusz Malinowski, Grzegorz Swirszcz, Joao Carreira, and Viorica Patraucean. Sideways: Depth-Parallel Training of Video Models. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11831–11840, Seattle, WA, USA, June 2020. IEEE. Sideways. 1, 2

[18] Mateusz Malinowski, Dimitrios Vytiniotis, Grzegorz Swirszcz, Viorica Patraucean, and Joao Carreira. Gradient Forward-Propagation for Large-Scale Temporal Video Modelling. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9245–9255, Nashville, TN, USA, June 2021. IEEE. Skip-Sideways. 1, 2

[19] Chao-Yuan Wu, Yanghao Li, Karttikeya Mangalam, Haoqi Fan, Bo Xiong, Jitendra Malik, and Christoph Feichtenhofer. Memvit: Memory-augmented multiscale vision transformer for efficient long-term video recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 13587–13597, June 2022. 1, 2

[20] Christoph Feichtenhofer. X3d: Expanding architectures for efficient video recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020. 1, 4, 5

[21] Hao Zhang, Yanbin Hao, and Chong-Wah Ngo. Token shift transformer for video classification. In *Proceedings of the 29th ACM International Conference on Multimedia*, MM '21, p. 917–925, New York, NY, USA, 2021. Association for Computing Machinery. 1, 2

[22] Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić, and Cordelia Schmid. Vivit: A video vision transformer. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 6836–6846, October 2021. 1, 2

[23] Gedas Bertasius, Heng Wang, and Lorenzo Torresani. Is space-time attention all you need for video understanding? In Marina Meila and Tong Zhang, editors, *Proceedings of the 38th International Conference on Machine Learning*, Vol. 139 of *Proceedings of Machine Learning Research*, pp. 813–824. PMLR, 18–24 Jul 2021. 1, 2

[24] Madeline C. Schiappa, Yogesh S. Rawat, and Mubarak Shah. Self-supervised learning for videos: A survey. *ACM Comput. Surv.*, Vol. 55, No. 13s, jul 2023. 1

[25] Chaoning Zhang, Chenshuang Zhang, Junha Song, John Seon Keun Yi, Kang Zhang, and In So Kweon. A survey on masked autoencoder for self-supervised learning in vision and beyond. *CoRR*, Vol. abs/2208.00173, , 2022. 1

[26] Limin Wang, Bingkun Huang, Zhiyu Zhao, Zhan Tong, Yinan He, Yi Wang, Yali Wang, and Yu Qiao. Videomae v2: Scaling video masked autoencoders with dual masking. In *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 14549–14560, 2023. 1

[27] Rohit Girdhar, Alaaeldin El-Nouby, Mannat Singh, Kalyan Vasudev Alwala, Armand Joulin, and Ishan Misra. OmniMAE: Single Model Masked Pretraining on Images and Videos. In *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 10406–10417, Vancouver, BC, Canada, June 2023. IEEE. OmniMAE. 1

[28] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 15979–15988, 2022. 1

[29] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021. 1

[30] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In Hal Daumé III and Aarti Singh, editors, *Proceedings of the 37th International Conference on Machine Learning*, Vol. 119 of *Proceedings of Machine Learning Research*, pp. 1597–1607. PMLR, 13–18 Jul 2020. 1

[31] Ashish Jaiswal, Ashwin Ramesh Babu, Mohammad Zaki Zadeh, Debapriya Banerjee, and Fillia Makedon. A survey on contrastive self-supervised learning. *Technologies*, Vol. 9, No. 1, 2021. 1

[32] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9726–9735, 2020. 1, 2

[33] Tian Pan, Yibing Song, Tianyu Yang, Wenhao Jiang, and Wei Liu. Videomoco: Contrastive video representation learning with temporally adversarial examples. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11200–11209, 2021. 1

[34] Jianping Gou, Baosheng Yu, Stephen J. Maybank, and Dacheng Tao. Knowledge Distillation: A Survey. *International Journal of Computer Vision*, Vol. 129, No. 6, pp. 1789–1819, June 2021. 1

[35] Chengming Hu, Xuan Li, Dan Liu, Haolun Wu, Xi Chen, Ju Wang, and Xue Liu. Teacher-student architecture for knowledge distillation: A survey. *CoRR*, Vol. abs/2308.04268, , 2023. 1

[36] Joao Carreira and Andrew Zisserman. Quo vadis, action recognition? a new model and the kinetics dataset. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, July 2017. 1

[37] Du Tran, Lubomir Bourdev, Rob Fergus, Lorenzo Torresani, and Manohar Paluri. Learning spatiotemporal features with 3d convolutional networks. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, December 2015. 1

[38] Kensho Hara, Hirokatsu Kataoka, and Yutaka Satoh. Can spatiotemporal 3d cnns retrace the history of 2d cnns and imagenet? In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018. 1

[39] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In Marina Meila and Tong Zhang, editors, *Proceedings of the 38th International Conference on Machine Learning*, Vol. 139 of *Proceedings of Machine Learning Research*, pp. 8748–8763. PMLR, 18–24 Jul 2021. 1

[40] Javier Selva, Anders Skaarup Johansen, Sergio Escalera, Kamal Nasrollahi, Thomas B. Moeslund, and Albert Clapés. Video transformers: A survey. In *CoRR*, Vol. abs/2201.05991, 2022. 1

[41] Bolin Ni, Houwen Peng, Minghao Chen, Songyang Zhang, Gaofeng Meng, Jianlong Fu, Shiming Xiang, and Haibin Ling. Expanding language-image pretrained models for general video recognition. In Shai Avidan, Gabriel Brostow, Moustapha Cissé, Giovanni Maria Farinella, and Tal Hassner, editors, *Computer Vision – ECCV 2022*, pp. 1–18, Cham, 2022. Springer Nature Switzerland. 1

[42] Hu Xu, Gargi Ghosh, Po-Yao Huang, Dmytro Okhonko, Armen Aghajanyan, Florian Metze, Luke Zettlemoyer, and Christoph Feichtenhofer. VideoCLIP: Contrastive pre-training for zero-shot video-text understanding. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pp. 6787–6800, Online and Punta Cana, Dominican Republic, November 2021. Association for Computational Linguistics. 1

[43] Mengmeng Wang, Jiazheng Xing, and Yong Liu. Actionclip: A new paradigm for video action recognition. *CoRR*, Vol. abs/2109.08472, , 2021. 1

[44] Will Kay, João Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijayanarasimhan, Fabio Viola, Tim Green, Trevor Back, Paul Natsev, Mustafa Suleyman, and Andrew Zisserman. The kinetics human action video dataset. *CoRR*, Vol. abs/1705.06950, , 2017. 1, 3, 4, 5

[45] Khurram Soomro, Amir Roshan Zamir, and Mubarak Shah. UCF101: A dataset of 101 human actions classes from videos in the wild. *CoRR*, Vol. abs/1212.0402, , 2012. 1, 3, 4, 5

[46] Swathikiran Sudhakaran, Sergio Escalera, and Oswald Lanz. Gate-shift networks for video action recognition. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020. 2

[47] Linxi Fan, Shyamal Buch, Guanzhi Wang, Ryan Cao, Yuke Zhu, Juan Carlos Niebles, and Li Fei-Fei. Rubiksnet: Learnable 3d-shift for efficient video action recognition. In Andrea Vedaldi, Horst Bischof, Thomas Brox, and Jan-Michael Frahm, editors, *Computer Vision – ECCV 2020*, Cham, 2020. Springer International Publishing. 2

[48] Adrian Bulat, Juan Manuel Perez Rua, Swathikiran Sudhakaran, Brais Martinez, and Georgios Tzimiropoulos. Space-time mixing attention for video transformer. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, Vol. 34, pp. 19594–19607. Curran Associates, Inc., 2021. 2

[49] Ryota Hashiguchi and Toru Tamaki. Temporal cross-attention for action recognition. In *Proceedings of the Asian Conference on Computer Vision (ACCV) Workshops*, pp. 276–288, December 2022. 2

[50] Saining Xie, Chen Sun, Jonathan Huang, Zhuowen Tu, and Kevin Murphy. Rethinking spatiotemporal feature learning: Speed-accuracy trade-offs in video classification. In *Proceedings of the European Conference on Computer Vision (ECCV)*, September 2018. 2

[51] Zhaofan Qiu, Ting Yao, and Tao Mei. Learning spatio-temporal representation with pseudo-3d residual networks. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, Oct 2017. 2

[52] Bo Pang, Gao Peng, Yizhuo Li, and Cewu Lu. Pgt: A progressive method for training models on long videos. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11374–11384, 2021. 2

[53] Xitong Yang, Haoqi Fan, Lorenzo Torresani, Larry Davis, and Heng Wang. Beyond short clips: End-to-end video-level learning with collaborative memories. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 7563–7572, 2021. 2

[54] Zhiwu Qing, Shiwei Zhang, Ziyuan Huang, Yi Xu, Xiang Wang, Mingqian Tang, Changxin Gao, Rong Jin, and Nong Sang. Learning from untrimmed videos: Self-supervised video representation learning with hierarchical consistency. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 13811–13821, 2022. 2

[55] Chao-Yuan Wu and Philipp Krähenbühl. Towards long-form video understanding. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1884–1894, 2021. 2

[56] Haoqi Fan, Bo Xiong, Karttikeya Mangalam, Yanghao Li, Zhicheng Yan, Jitendra Malik, and Christoph Feichtenhofer. Multiscale vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 6824–6835, October 2021. 2

[57] Aäron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding. *CoRR*, Vol. abs/1807.03748, , 2018. 3

[58] Chunhui Gu, Chen Sun, David A. Ross, Carl Vondrick, Caroline Pantofaru, Yeqing Li, Sudheendra Vijayanarasimhan, George Toderici, Susanna Ricco, Rahul Sukthankar, Cordelia Schmid, and Jitendra Malik. AVA: A video dataset of spatio-temporally localized atomic visual actions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018. 3, 4, 5

[59] Hildegard Kuehne, Hueihan Jhuang, Estíbaliz Garrote, Tomaso A. Poggio, and Thomas Serre. HMDB: A large video database for human motion recognition. In Dimitris N. Metaxas, Long Quan, Alberto Sanfeliu, and Luc Van Gool, editors, *IEEE International Conference on Computer Vision, ICCV 2011, Barcelona, Spain, November 6-13, 2011*, pp. 2556–2563. IEEE Computer Society, 2011. 3, 4, 5

[60] Dima Damen, Hazel Doughty, Giovanni Maria Farinella, Antonino Furnari, Evangelos Kazakos, Jian Ma, Davide Moltisanti, Jonathan Munro, Toby Perrett, Will Price, and Michael Wray. Rescaling egocentric vision: Collection, pipeline and challenges for EPIC-KITCHENS-100. *Int. J. Comput. Vis.*, Vol. 130, No. 1, pp. 33–55, 2022. 3

[61] Sebastian Stein and Stephen J. McKenna. Combining embedded accelerometers with computer vision for recognizing food preparation activities. In *Proceedings of the 2013 ACM International Joint Conference on Pervasive and Ubiquitous Computing*, UbiComp '13, pp. 729–738, New York, NY, USA, 2013. Association for Computing Machinery. 3

[62] Antoine Miech, Dimitri Zhukov, Jean-Baptiste Alayrac, Makarand Tapaswi, Ivan Laptev, and Josef Sivic. Howto100m: Learning a text-video embedding by watching hundred million narrated video clips. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, October 2019. 3

[63] Andrej Karpathy, George Toderici, Sanketh Shetty, Thomas Leung, Rahul Sukthankar, and Li Fei-Fei. Large-scale video classification with convolutional neural networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2014. 3

[64] Syed Sahil Abbas Zaidi, Mohammad Samar Ansari, Asra Aslam, Nadia Kanwal, Mamoona Asghar, and Brian Lee. A survey of modern deep learning based object detection models. *Digital Signal Processing*, Vol. 126, p. 103514, 2022. 4

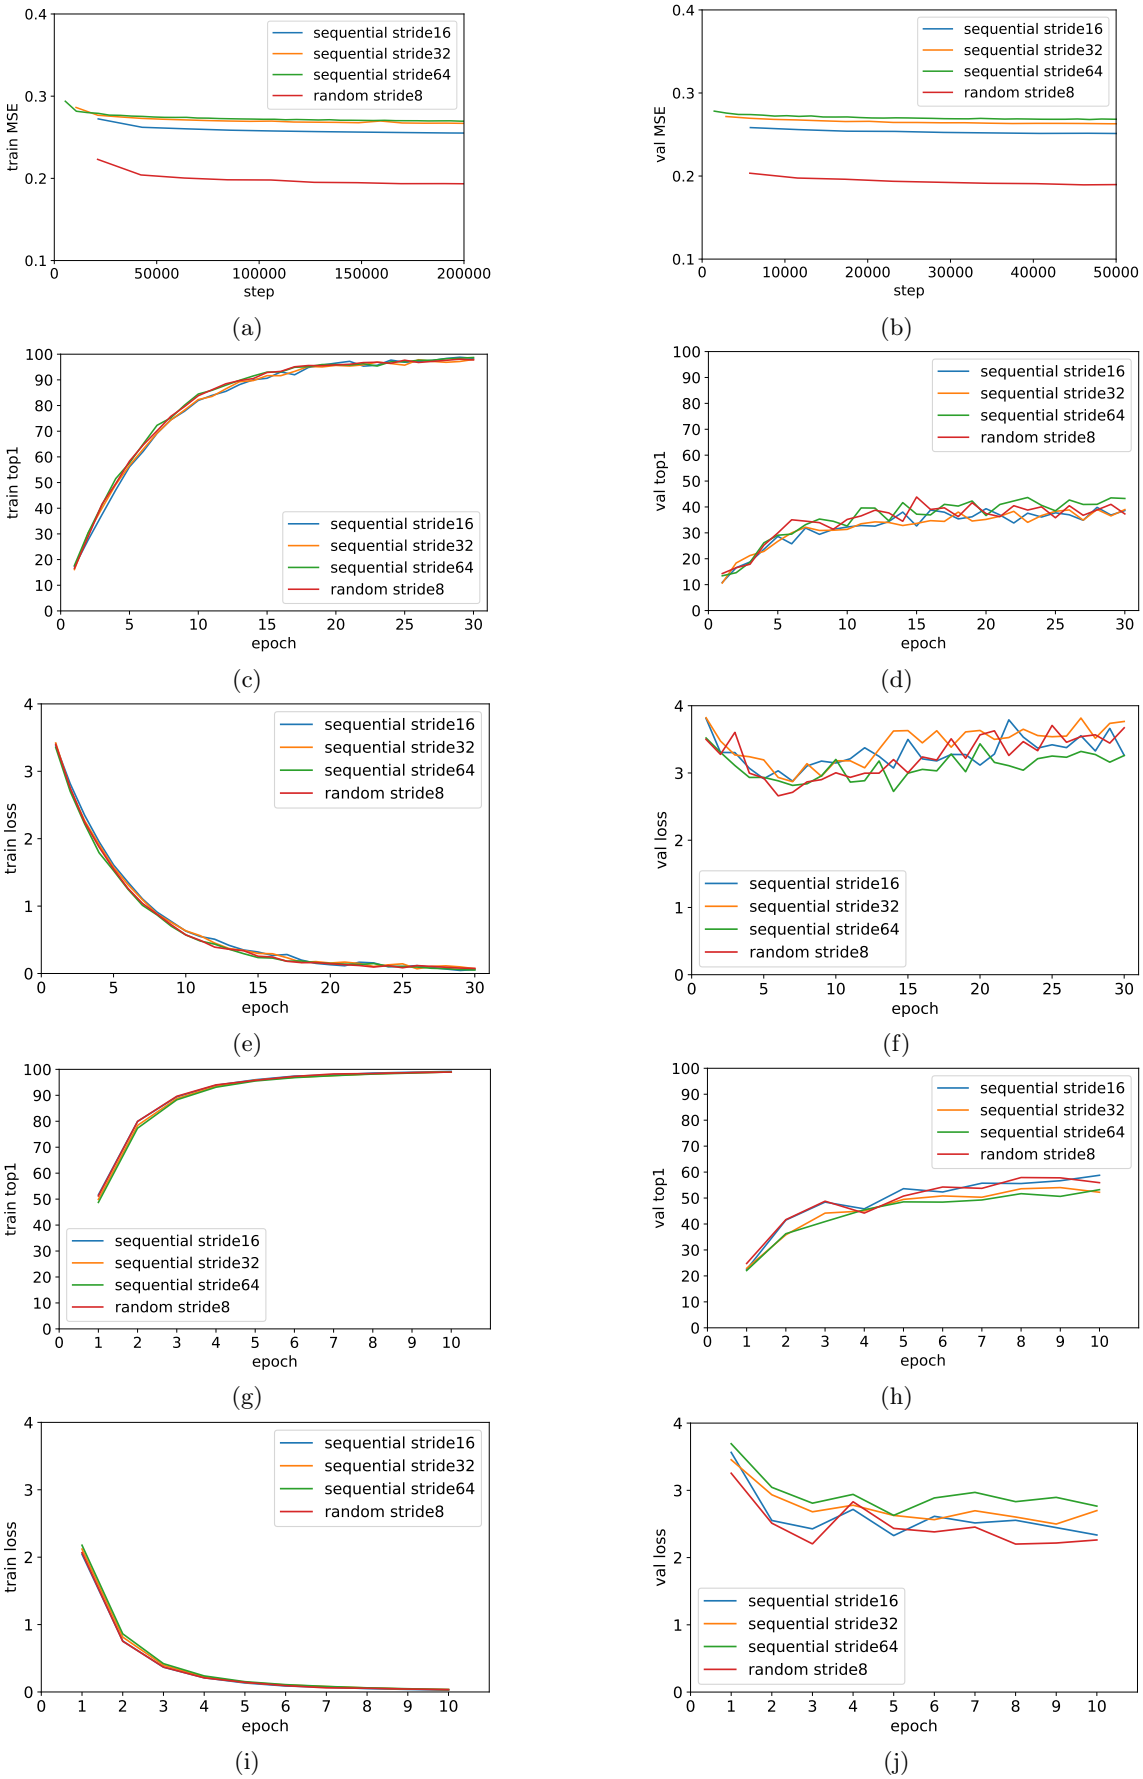


図 6: MIM の実験結果．事前学習における (a) 学習時と (b) 評価時の損失（MSE）．HMDB51 を用いた下流タスクにおける (c) 学習時と (d) 評価時の top1 性能および (e) 学習時と (f) 評価時の損失と，UCF101 を用いた下流タスクにおける (g) 学習時と (h) 評価時の top1 性能および (i) 学習時と (j) 評価時の損失.

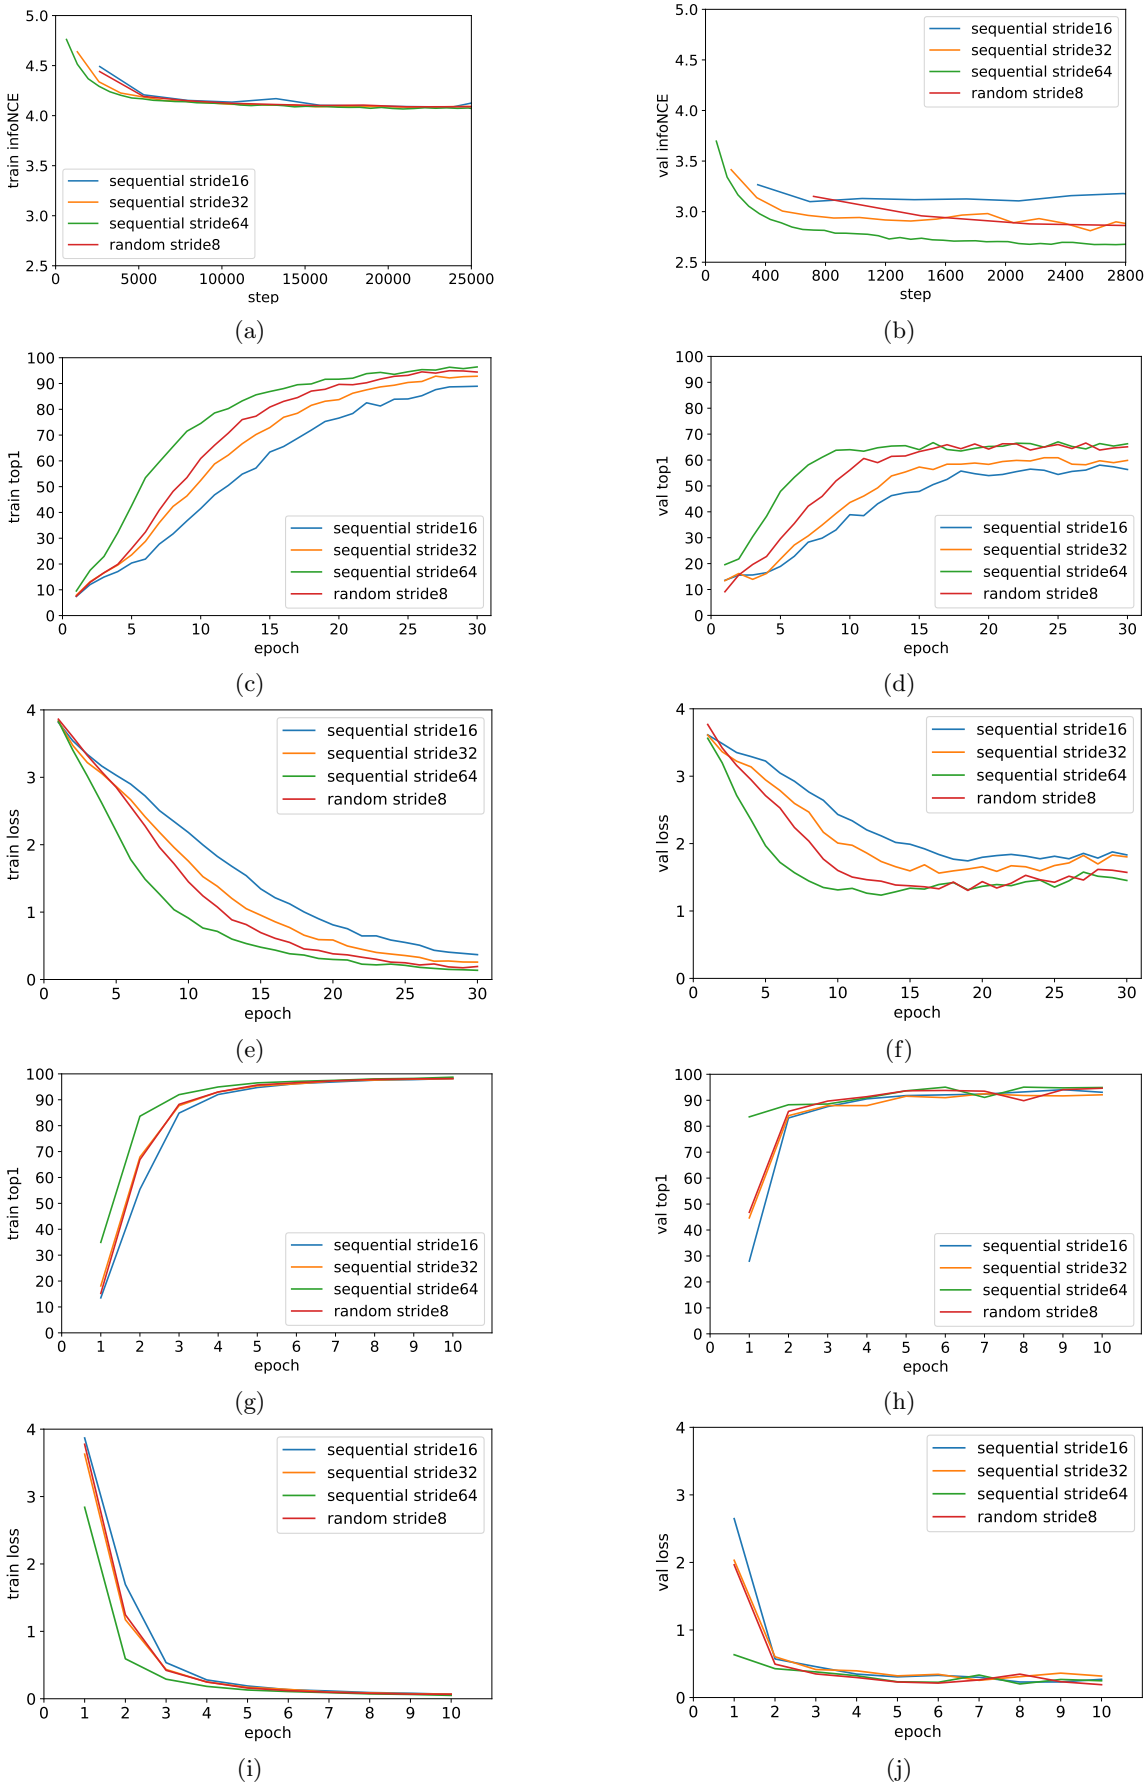


図 7: 対照学習の実験結果．事前学習における (a) 学習時と (b) 評価時の損失（infoNCE）．HMDB51 を用いた下流タスクにおける (c) 学習時と (d) 評価時の top1 性能および (e) 学習時と (f) 評価時の損失と，UCF101 を用いた下流タスクにおける (g) 学習時と (h) 評価時の top1 性能および (i) 学習時と (j) 評価時の損失．

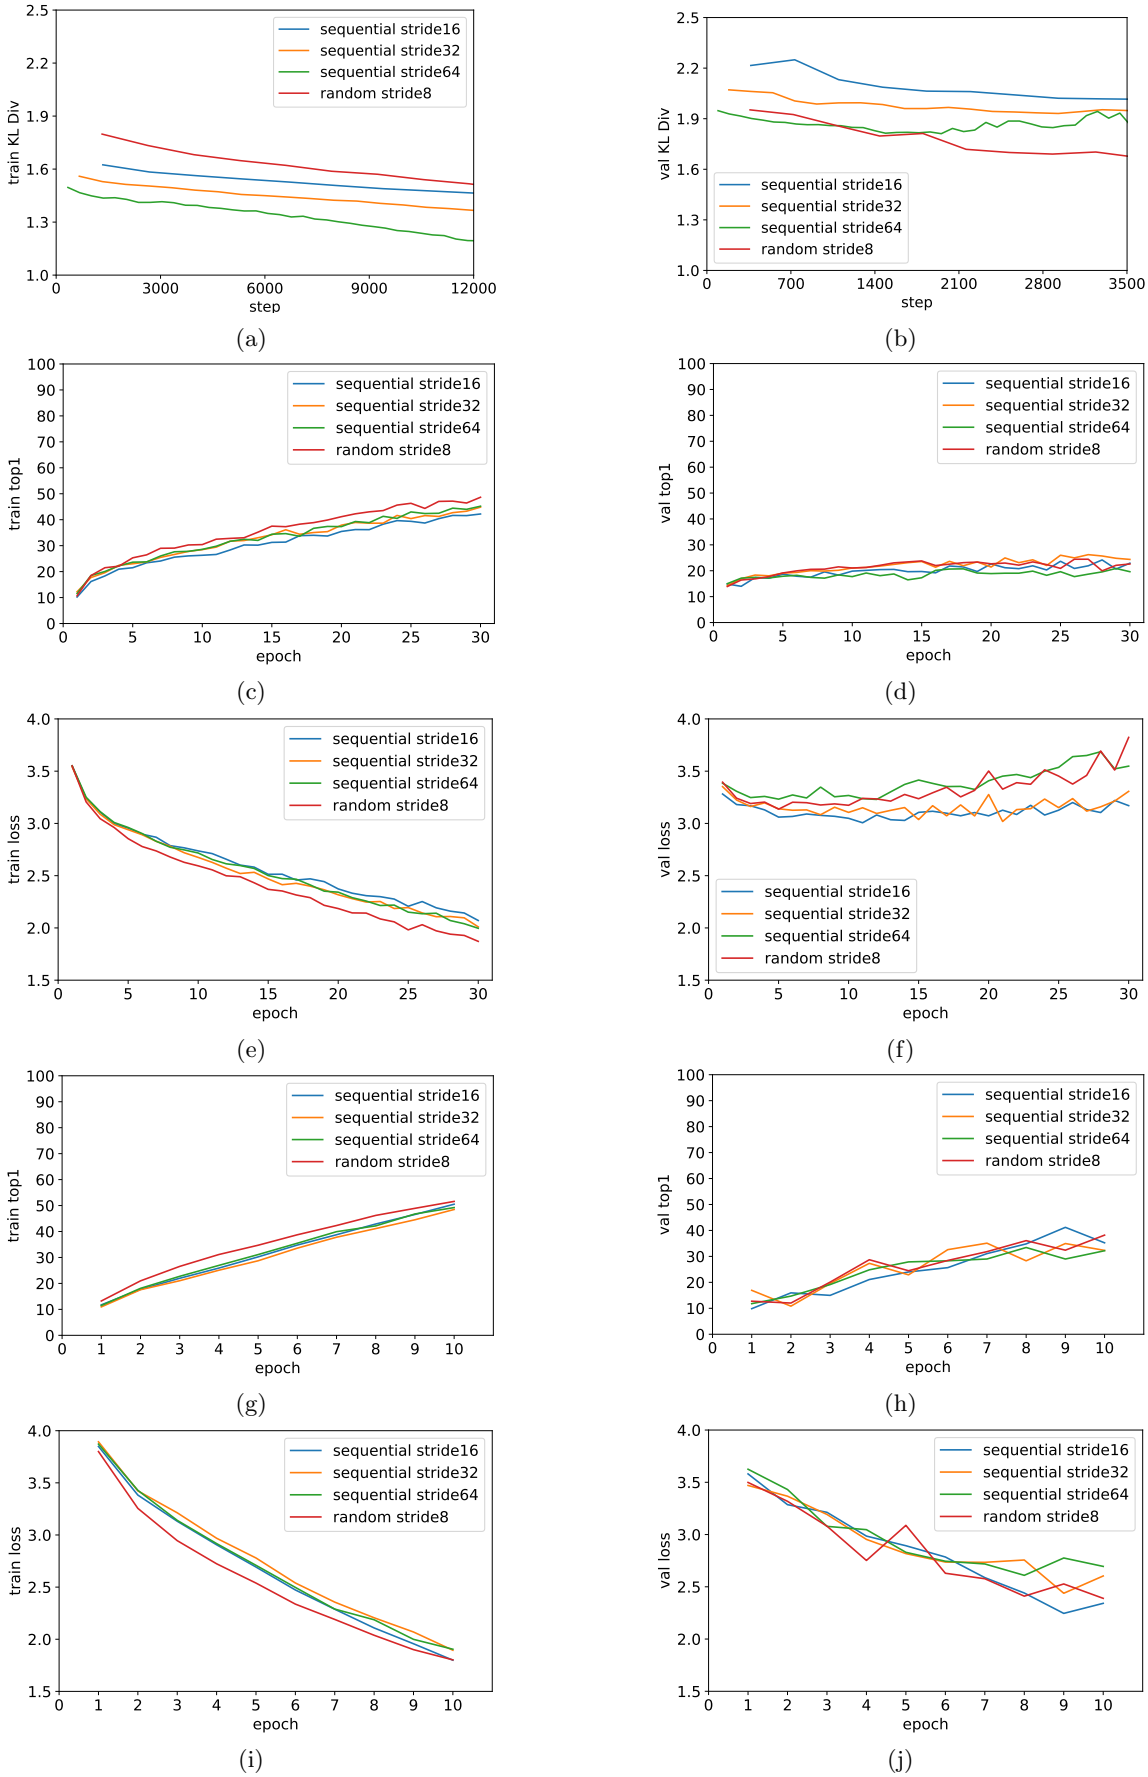


図 8: TSL の実験結果．事前学習における (a) 学習時と (b) 評価時の損失（KL Divergence）．HMDB51 を用いた下流タスクにおける (c) 学習時と (d) 評価時の top1 性能および (e) 学習時と (f) 評価時の損失と，UCF101 を用いた下流タスクにおける (g) 学習時と (h) 評価時の top1 性能および (i) 学習時と (j) 評価時の損失．